

Análise do Notebook

RNAAPIA — Face Recognition Pipeline

Relatório de análise dos resultados obtidos no notebook de reconhecimento facial. Cobre as fases de preparação do dataset, treino comparativo entre FaceCNN e ResNet-50, e observações sobre o comportamento dos modelos.

GPU	Tesla T4 — 15.6 GB VRAM
Dataset	VGGFace2 (480 identidades disponíveis)
Identities usadas	50
IMAGE_SIZE	192×192 px (calculado pela mediana)
Split	70% treino / 15% val / 15% teste
Épocas	30 por modelo

1. Análise e Preparação do Dataset

1.1 Distribuição de Tamanhos das Imagens Originais

Antes de proceder ao alinhamento facial, foi realizada uma análise estatística dos tamanhos originais das imagens do dataset VGGFace2. Foram amostradas 50 identidades com 20 imagens cada, totalizando 1000 imagens analisadas.

Dimensão	Mínimo	Mediana	Máximo	Média
Largura (px)	52	219	934	245
Altura (px)	60	234	1007	263




Figura 1 — Distribuição de larguras e alturas das imagens originais do VGGFace2. A mediana (linha vermelha) e a média (linha laranja) indicam uma concentração de imagens na gama 200–300px.

A mediana do lado menor foi de 219px (largura). Arredondando para o múltiplo de 32 imediatamente inferior, o `IMAGE_SIZE` foi definido automaticamente como **192×192 px**. Esta abordagem evita o downscaling excessivo que ocorreria com o tamanho padrão de 112×112 px do MTCNN, preservando mais detalhe facial.

1.2 Alinhamento MTCNN

O MTCNN foi configurado com `image_size=192px` e `margem=32px` (`IMAGE_SIZE // 6`). Foram processadas 50 identidades, das quais 30 estavam por processar na sessão registada (20 já tinham sido concluídas numa sessão anterior). O processo decorreu sem falhas.

Parâmetro	Valor
<code>image_size</code>	192 px
<code>margin</code>	32 px
<code>min_face_size</code>	20 px
<code>device</code>	cuda (Tesla T4)
Imagens alinhadas (total)	10 444

Falhas de deteção	0
-------------------	---

1.3 Filtragem e Remoção de Outliers

Após o alinhamento, o dataset completo continha 16 879 imagens distribuídas pelas 50 identidades. Foi aplicado o método IQR para detetar outliers.

Métrica	Valor
Total antes da filtragem	16 879 imagens
Mínimo por identidade	156 imagens
Mediana por identidade	343 imagens
Máximo por identidade	517 imagens
Limite inferior IQR	88 imagens
Limite superior IQR	571 imagens
Outliers removidos	0
Máximo após equalização (mediana)	343 imagens
Total final	15 236 imagens




Figura 2 — Distribuição do número de imagens por identidade após o MTCNN. Nenhum outlier foi detetado pelo método IQR, mas o dataset foi equalizado ao máximo de 343 imagens por identidade (mediana).

O dataset final ficou com **15 236 imagens de 50 identidades**, dividido em train (10 665) / val (2 285) / test (2 286), correspondendo ao split 70/15/15.

2. Treino dos Modelos

2.1 Configuração Comum

Ambos os modelos foram treinados nas mesmas condições para garantir uma comparação justa.

Parâmetro	Valor
Otimizador	Adam (lr=1e-3, weight_decay=1e-4)
Scheduler	CosineAnnealingLR (T_max=30, eta_min=1e-6)
Loss	Cross-Entropy
Batch size	64
Épocas	30
Mixed precision	torch.amp.autocast (CUDA)
Dropout	0.4 (camada de embedding)

2.2 FaceCNN — Arquitetura Própria

A FaceCNN foi desenhada de raiz para este problema. Consiste em 4 blocos convolucionais (Conv2d → BatchNorm → ReLU → MaxPool) seguidos de uma camada de embedding FC(512) e um classificador FC(50). Com IMAGE_SIZE=192px, o feature map após os 4 blocos tem dimensão 12×12, resultando em $256 \times 12 \times 12 = 36\,864$ features antes do embedding.

Arquitetura: 3 → 32 → 64 → 128 → 256 canais | Embedding: 36864 → 512 | Saída: 512 → 50

Evolução do treino (FaceCNN): A rede partiu de 39.2% de accuracy no primeiro epoch, atingiu 78.9% no epoch 3, e foi progressivamente melhorando até atingir o máximo de **90.02%** no epoch 27. Nos últimos 3 epochs a accuracy de validação estabilizou entre 89.5–90.0%, indicando convergência.

Epoch	Train Loss	Train Acc	Val Loss	Val Acc
1	2.4013	39.2%	1.5957	59.7%
5	0.4672	87.4%	0.8313	78.3%
10	0.1759	95.3%	0.6013	84.0%
15	0.0985	97.7%	0.5238	86.3%
20	0.0526	98.9%	0.4549	88.5%
25	0.0299	99.3%	0.4074	89.2%
27	0.0260	99.5%	0.3901	90.0% ✓

30	0.0238	99.5%	0.4046	89.5%
----	--------	-------	--------	-------

Tabela 1 — Evolução do treino da FaceCNN (épocas selecionadas). A linha verde corresponde ao melhor epoch.

2.3 ResNet-50 — Sem Pré-treino

A ResNet-50 foi usada sem pesos ImageNet (weights=None), com a camada FC original substituída por um embedding FC(512) seguido de classificador FC(50). O modelo tem 24.6M parâmetros.

Evolução do treino (ResNet-50): A rede teve um arranque mais lento, começando em 7.0% no primeiro epoch. Até ao epoch 8 manteve-se abaixo de 70%, exibindo instabilidade na validação (epoch 6: val 44.2%, epoch 8: val 69.1%). A partir do epoch 16 estabilizou e convergiu progressivamente até **90.24%** no epoch 30.

Epoch	Train Loss	Train Acc	Val Loss	Val Acc
1	3.6784	7.0%	3.3481	12.2%
5	1.5539	55.3%	1.8675	49.2%
8	1.0254	70.3%	1.1371	69.1%
10	0.8209	76.2%	1.2087	65.7%
15	0.4525	86.6%	0.8883	74.8%
20	0.1724	95.1%	0.5448	85.4%
25	0.0640	98.5%	0.4289	88.8%
30	0.0344	99.3%	0.3949	90.2% ✓

Tabela 2 — Evolução do treino da ResNet-50 (épocas selecionadas). A linha verde corresponde ao melhor epoch.

3. Comparação de Resultados

3.1 Tabela Comparativa

Métrica	FaceCNN (própria)	ResNet-50
Parâmetros	19.29M	24.6M
Melhor val_acc	90.02%	90.24%
Epoch do melhor resultado	27	30
Tempo por época	~24s	~40s
Train acc no melhor epoch	99.5%	99.3%
Val loss no melhor epoch	0.3901	0.3949
Arranque (epoch 1 val acc)	59.7%	12.2%
Estabilidade inicial	Rápida e monotônica	Lenta com oscilações

Tabela 3 — Comparação direta entre FaceCNN e ResNet-50. Células a verde indicam o melhor valor em cada métrica.




Figura 3 — Comparação das curvas de val loss e val accuracy ao longo das 30 épocas. A FaceCNN (azul) converge mais rapidamente, enquanto a ResNet-50 (vermelho) exibe maior instabilidade nas primeiras épocas.

3.2 Análise e Interpretação

Resultado final equivalente. A diferença de apenas 0.22 pontos percentuais (90.02% vs 90.24%) é estatisticamente irrelevante. Ambos os modelos convergiram para o mesmo patamar de performance com 50 identidades e ~15 000 imagens.

Velocidade de convergência. A FaceCNN convergiu significativamente mais rápido: atingiu 78.9% no epoch 3, enquanto a ResNet-50 ainda estava em 35.7%. Isto deve-se ao facto de a FaceCNN ter uma arquitetura mais simples e adaptada ao tamanho do dataset. Uma rede com 40M+ parâmetros precisa de mais épocas para inicializar os pesos de forma útil.

Instabilidade inicial da ResNet-50. Entre os epochs 5 e 10 a val accuracy oscilou entre 44.2% e 69.1%, sugerindo que o otimizador estava ainda a explorar o espaço de parâmetros de uma rede grande. A FaceCNN não exibiu este comportamento, com a val accuracy a crescer de forma monotónica até ao epoch 19.

Overfitting em ambos os modelos. No melhor epoch, ambos apresentam train acc de ~99.5% vs val acc de ~90%. A diferença de ~9-10 pontos percentuais indica overfitting moderado. Isto é esperado com um dataset desta dimensão e pode ser mitigado com mais regularização (aumento do dropout, weight decay mais alto) ou mais dados.

Eficiência computacional. A FaceCNN é ~67% mais rápida por época (24s vs 40s). Ao longo de 30 épocas, isso representa uma poupança de ~8 minutos de GPU. Para iterações rápidas de experimentação, esta diferença é relevante.

4. Próximos Passos

4.1 Dataset Organizacional

A fase seguinte consiste em recolher 5–10 fotografias de cada um dos 5 membros da organização e proceder ao fine-tuning do melhor modelo (FaceCNN ou ResNet-50). Algumas recomendações para a recolha de dados:

- Fotografias em condições diversas: interior, exterior, luz natural e artificial
- Variação de ângulo: frontal, 3/4 esquerda, 3/4 direita
- Variação de expressão: neutro, sorriso, sério
- Evitar óculos de sol ou chapéus que cubram a face
- Resolução mínima de 300×300px para garantir deteção pelo MTCNN
- As fotografias serão processadas para 192×192px (mesmo IMAGE_SIZE do treino principal)

Com 5–10 fotos por pessoa e o augmentation configurado (×20), cada pessoa terá 100–200 imagens para fine-tuning — suficiente para o modelo adaptar os embeddings às 5 identidades organizacionais.

4.2 Avaliação FAR/FRR/EER

Após o fine-tuning, será realizada a avaliação de segurança biométrica com as métricas standard para sistemas de controlo de acesso:

Métrica	Descrição
FAR (False Accept Rate)	Taxa de acesso concedido a impostores
FRR (False Reject Rate)	Taxa de rejeição de utilizadores legítimos
EER (Equal Error Rate)	Ponto onde FAR = FRR — threshold ótimo do sistema
Cosine Similarity	Métrica de comparação entre embeddings na galeria

4.3 Demo em Tempo Real

O script `realtime_access_control.py` gerado pelo notebook permite executar o sistema localmente com uma webcam. O threshold é calibrado automaticamente pelo EER calculado na fase de avaliação, garantindo um equilíbrio entre segurança e usabilidade.

Conclusão: O pipeline está concluído até à fase de comparação de modelos. Ambos os modelos atingiram ~90% de accuracy em 50 identidades do VGGFace2, com a FaceCNN a demonstrar vantagens claras em velocidade e estabilidade de convergência. A fase seguinte depende da

recolha do dataset organizacional.